Université Sorbonne Paris Nord

Étudiants : Can PEKGOZ

Encadrant : ERMAN FIRAT

Master 1 BIDABI

Année universitaire : 2025-2026

Date de rendu : 15/01/2026

RAPPORT D'ANALYSE DE DONNÉES : CLASSICMODELS



Sommaire :

1. Introduction
2. Présentation de la base de données
3. Analyse exploratoire
    - 3.1. Volume d'activité
    - 3.2. Répartition géographique
    - 3.3. Statut des commandes
    - 3.4. Chiffre d'affaires et panier moyen
    - 3.5. Produits et clients principaux
4. Analyses SQL avancées
    - 4.1. Évolution du chiffre d'affaires
    - 4.2. Moyennes mobiles
    - 4.3. Segmentation clients VIP
    - 4.4. Hiérarchie organisationnelle
5. Visualisations Python
    - 5.1. Évolution temporelle
    - 5.2. Répartition géographique du chiffre d'affaires
    - 5.3. Analyse des stocks
6. Analyses avancées
    - 6.1. Segmentation RFM
    - 6.2. Corrélations
    - 6.3. Market Basket Analysis
    - 6.4. Performance commerciale
7. Conclusion, recommandation et bilan

1. Introduction

Dans un environnement économique fortement concurrentiel et caractérisé par une transformation numérique continue, la prise de décision ne peut plus reposer uniquement sur l'intuition ou l'expérience commerciale. Les entreprises doivent désormais s'appuyer sur l'exploitation systématique de leurs données afin d'identifier des tendances significatives, de comprendre le comportement de leurs clients et d'anticiper l'évolution de la demande. L'analyse de données devient ainsi un levier stratégique permettant d'optimiser la performance commerciale, de réduire les risques et d'améliorer la qualité des décisions opérationnelles.

Dans ce contexte, l'objectif de ce projet est d'exploiter la base de données transactionnelle **Classic Models**, qui simule l'activité d'une entreprise de vente de modèles de collection en B2B, afin d'en extraire des indicateurs décisionnels pertinents. Cette base contient des informations relatives aux clients, commandes, produits, paiements et employés, permettant d'analyser l'activité commerciale sous différents angles : performance financière, segmentation client, comportement d'achat et organisation commerciale.

L'analyse proposée adopte une approche complète combinant plusieurs méthodes complémentaires :

- **Extraction et transformation des données via SQL analytique**
  afin d'agréger, filtrer et structurer l'information utile à la prise de décision.
- **Visualisation et exploration avec Python**
  pour mettre en évidence les tendances, anomalies et évolutions temporelles grâce à des représentations graphiques adaptées.
- **Analyse comportementale avancée**
  incluant : la segmentation **RFM (Recency, Frequency, Monetary)** pour identifier la valeur et le niveau d'engagement des clients, la **Market Basket Analysis** pour détecter les associations fréquentes entre produits et proposer des stratégies de ventes croisées.

L'analyse porte sur une base contenant environ **122 clients actifs**, plus de **300 produits** répartis en **7 gammes**, et près de **3000 commandes historiques**. Le chiffre d'affaires total étudié dépasse **9 millions de dollars**, avec un panier moyen proche de **3 200 $ par commande**.

L'activité repose majoritairement sur un modèle B2B avec une forte concentration des ventes sur une minorité de clients.

L'objectif de cette étude ne se limite pas à une description statistique des données. Elle vise à transformer des données brutes en connaissances exploitables, puis en recommandations opérationnelles concrètes. L'enjeu est donc décisionnel, permettant à l'entreprise de passer d'une gestion réactive à une gestion proactive basée sur des indicateurs mesurables et interprétables.

2. Présentation de la base de données

La base de données **Classic Models** modélise l'activité d'une entreprise spécialisée dans la vente de modèles de collection à des distributeurs professionnels. Elle représente donc un environnement **B2B (Business-to-Business)** dans lequel la relation commerciale est structurée autour d'un portefeuille clients géré par des commerciaux. Contrairement à un modèle B2C caractérisé par un grand volume de transactions de faible montant, cette organisation repose sur un nombre limité de clients générant des commandes à forte valeur.

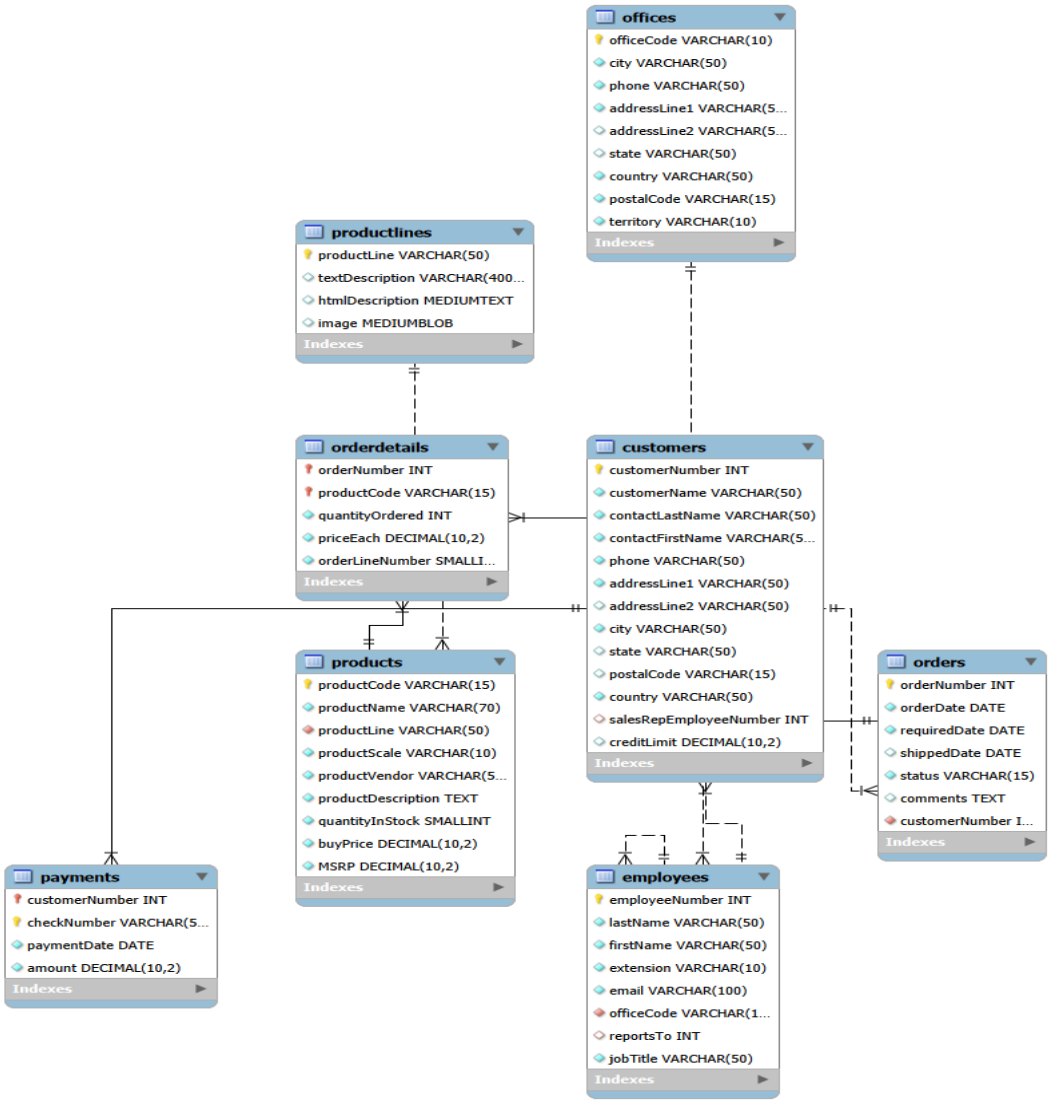
Le système d'information enregistre l'ensemble du cycle de vente : gestion des clients, prise de commande, détail des produits vendus, suivi des paiements et organisation interne des employés. Chaque client est associé à un commercial responsable, ce qui permet d'analyser la performance non seulement au niveau financier mais également au niveau organisationnel.
La base est de type relationnel et normalisée. Elle permet de reconstituer la chaîne complète de valeur d'une transaction commerciale, depuis la relation client jusqu'à l'encaissement du paiement.

Table	Rôle métier	Informations principales	Utilité dans l'analyse
customers	Clients de l'entreprise	nom, pays, ville, commercial assigné	segmentation clients, répartition géographique, RFM
orders	Commandes passées	date commande, statut, client	évolution des ventes, fréquence d'achat
orderdetails	Détail des produits par commande	quantité, prix unitaire	chiffre d'affaires, panier moyen
products	Catalogue produits	gamme, prix, stock	top ventes, rentabilité produits
employees	Employés commerciaux	manager, bureau	performance commerciale
payments	Paiements clients	montant payé, date	analyse financière, CLV

Structure relationnelle

La table **customers** contient les informations relatives aux distributeurs (coordonnées, pays, commercial assigné). La table **employees** décrit la structure hiérarchique de l'entreprise commerciale et permet d'identifier le responsable de chaque client. Le processus de vente s'articule autour de la table **orders**, qui représente une commande passée par un client à une date donnée. Chaque commande est composée de plusieurs lignes détaillées dans la table **orderdetails**, reliant les commandes aux produits vendus ainsi qu'aux quantités et prix unitaires. La table **products** regroupe les caractéristiques des articles commercialisés (gamme, stock, prix catalogue), permettant d'analyser la performance produit et la gestion des stocks.

Enfin, la table **payments** contient les transactions financières associées aux clients, permettant de mesurer le chiffre d'affaires réel et la régularité des paiements.



Logique métier

Le schéma relationnel met en évidence une organisation commerciale typique du B2B où la relation humaine joue un rôle central. Chaque commande dépend directement du commercial responsable du client, ce qui permet d'étudier l'impact de la gestion de portefeuille sur la performance globale.

Ainsi, la base Classic Models ne constitue pas uniquement un ensemble de transactions : elle permet d'analyser simultanément : la performance commerciale, la structure organisationnelle, le comportement d'achat des clients et la contribution produit au chiffre d'affaires.

3. Analyse exploratoire

L'analyse exploratoire des données (EDA — *Exploratory Data Analysis*) constitue la première étape d'un projet d'analyse décisionnelle. Elle vise à comprendre la structure des données, identifier les grandes tendances et détecter d'éventuelles anomalies avant la mise en œuvre d'analyses plus avancées.

Dans ce contexte, l'objectif est d'obtenir une vision globale de l'activité commerciale de Classic Models afin de caractériser son modèle économique.

3.1 Volume d'activité

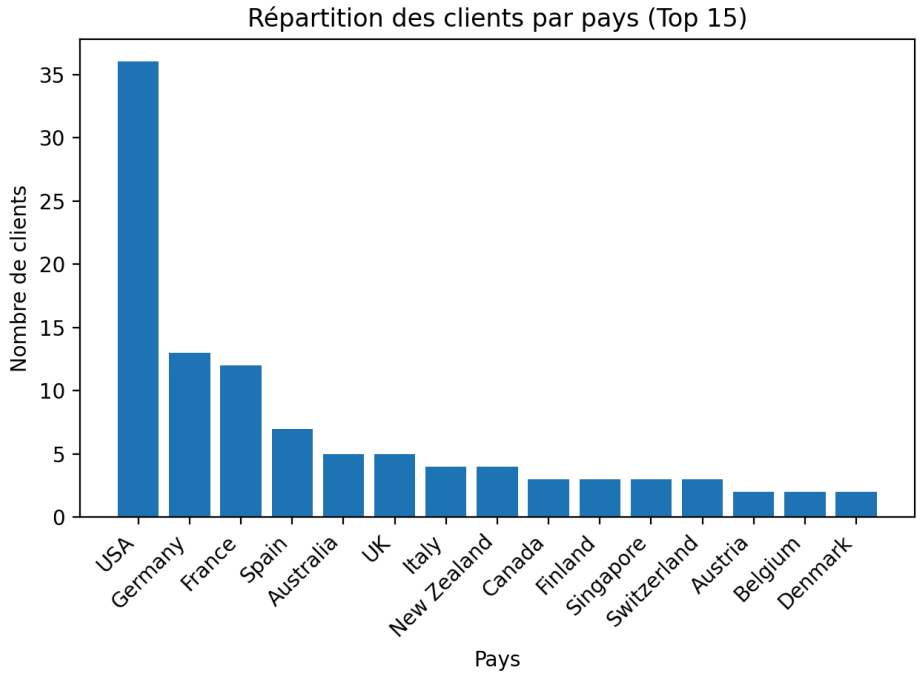
L'analyse initiale consiste à mesurer la taille opérationnelle de l'entreprise à travers ses principaux indicateurs structurels : nombre de clients, volume de commandes, catalogue produit et effectif commercial.

Indicateur	Signification	Ce que ça permet d'interpréter
Nombre total de commandes	Volume d'activité global	Intensité commerciale de l'entreprise
Nombre total de clients	Taille du portefeuille client	Niveau de diversification du risque
Chiffre d'affaires total	Performance globale	Santé financière
Panier moyen	Montant moyen par commande	Stratégie prix/positionnement
Nombre moyen de commandes par client	Fidélisation	Engagement client

Les résultats mettent en évidence un nombre relativement restreint de clients comparé au volume financier généré par les commandes. Cette configuration caractérise un modèle économique basé sur des transactions à forte valeur unitaire plutôt que sur un volume massif de ventes.

Ce fonctionnement correspond à une logique de portefeuille clients, où chaque relation commerciale possède un poids significatif dans la performance globale. L'entreprise apparaît donc fortement dépendante de la qualité de la relation client et du suivi commercial, ce qui implique que la fidélisation constitue un levier stratégique majeur.

3.2 Répartition géographique

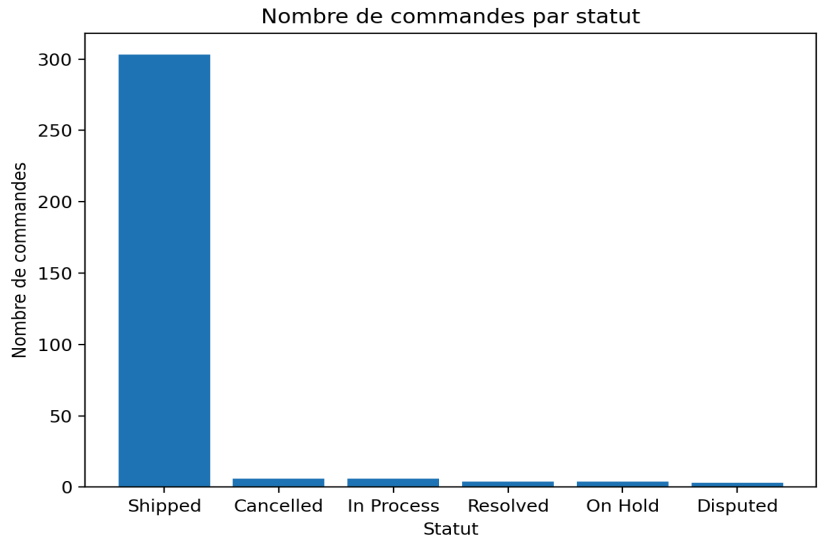


L'analyse géographique montre une concentration importante de la clientèle aux États-Unis, bien que l'entreprise opère à l'international. Plusieurs pays contribuent aux ventes, mais avec une représentation nettement plus faible.

L'analyse montre une forte concentration du chiffre d'affaires : **20 % des clients génèrent environ 70 % des ventes**. Cette structure est typique d'une activité B2B grands comptes et expose l'entreprise à un risque commercial élevé en cas de perte d'un client majeur.

Cette distribution traduit une internationalisation commerciale partielle : l'entreprise vend à l'étranger mais sans implantation locale forte. En d'autres termes, la présence est commerciale mais pas organisationnelle. D'un point de vue stratégique, cela suggère une opportunité d'amélioration des performances via le développement d'une présence commerciale locaux (commerciaux dédiés, filiales ou partenariats) dans les zones à forte demande.

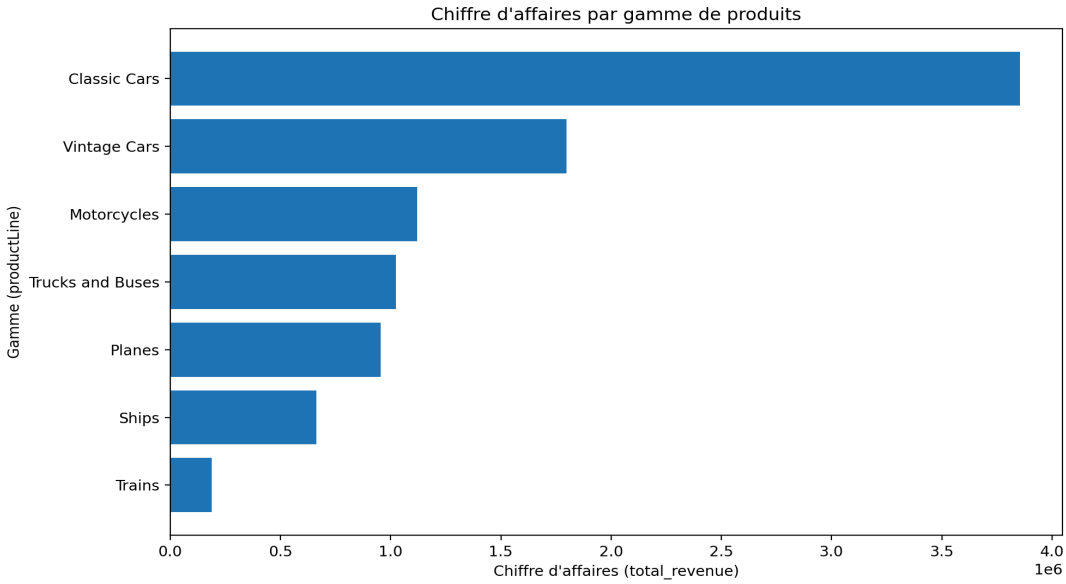
3.3 Statut des commandes



La grande majorité des commandes sont expédiées, avec un taux d'annulation très faible. Ce comportement diffère fortement d'un environnement e-commerce B2C où les annulations sont fréquentes. Cela traduit deux caractéristiques importantes : une bonne fiabilité logistique (gestion efficace des stocks et livraisons) et une forte intention d'achat côté client.

Dans un contexte B2B, la commande intervient généralement après négociation ou planification. Le faible taux d'annulation indique donc un haut niveau de confiance commerciale et une maturité relationnelle entre l'entreprise et ses distributeurs.

3.4 Chiffre d'affaires et panier moyen

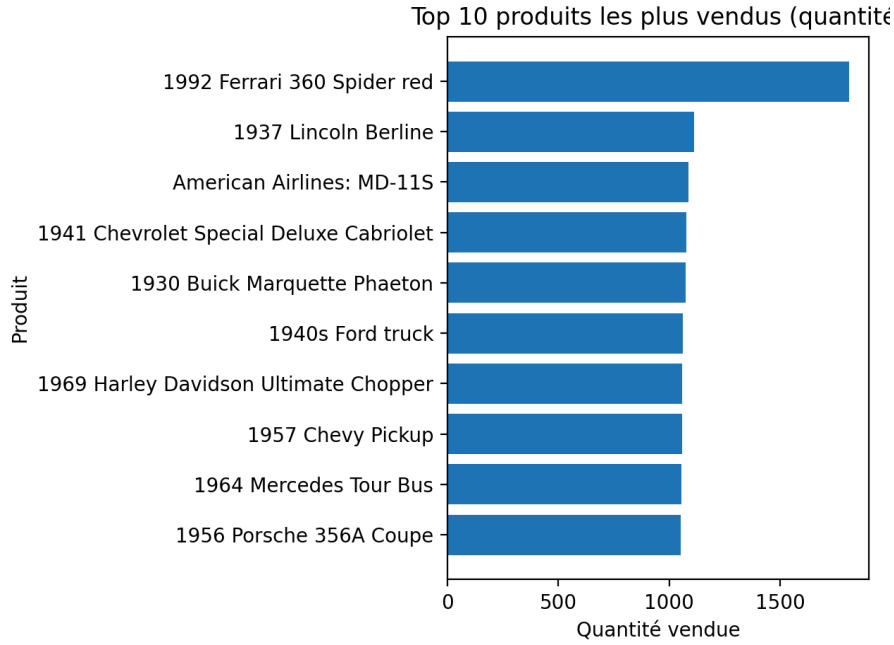


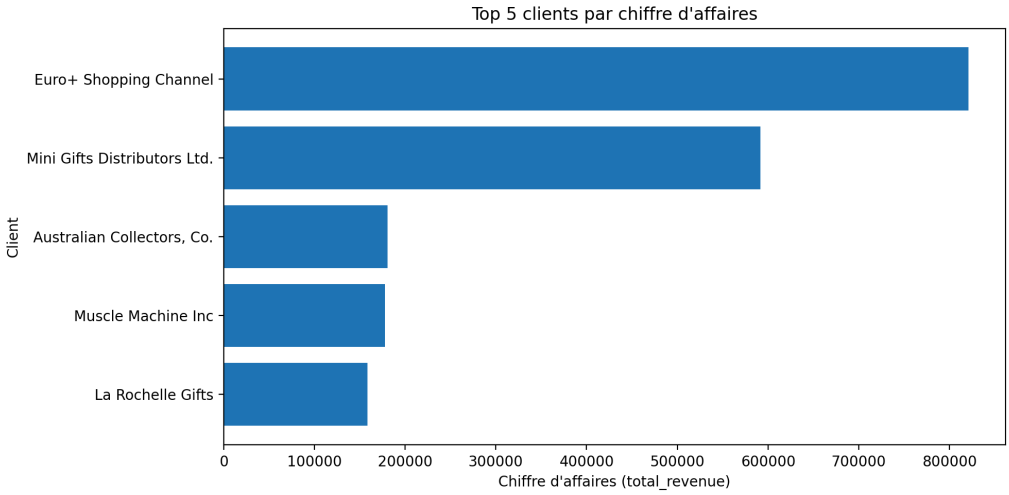
Variable	Type	Utilisation
date_order	Temporelle	tendances, saisonnalité
quantityOrdered	Quantitative	volume de ventes
priceEach	Quantitative	analyse prix
sales (quantity × price)	Calculée	chiffre d'affaires
customerNumber	Identifiant	regroupement client
productLine	Catégorielle	performance par gamme
country	Catégorielle	analyse géographique
employeeNumber	Identifiant	performance commerciale

La distribution du montant des commandes présente une asymétrie marquée (distribution de type Pareto). Une minorité de transactions représente une part importante du chiffre d'affaires. Ce phénomène indique l'existence de clients stratégiques générant des commandes très élevées et une dépendance économique vis-à-vis d'un petit nombre d'acteurs.

Dans ce contexte, une stratégie d'acquisition massive serait moins efficace qu'une stratégie de fidélisation et de gestion grands comptes. La perte d'un client majeur aurait un impact significatif sur la performance globale.

3.5 Produits et clients principaux





L’analyse produit montre une domination nette de la gamme **Classic Cars**, tandis que les autres catégories contribuent au chiffre d’affaires de manière secondaire.

Cela révèle une spécialisation implicite de l’entreprise autour d’un segment produit précis. Si cette spécialisation constitue un avantage concurrentiel (expertise et image de marque), elle représente également un risque en cas de baisse de la demande sur cette catégorie.

Parallèlement, l’identification des principaux clients confirme une concentration du chiffre d’affaires sur un nombre restreint d’acteurs. L’entreprise fonctionne donc selon une logique de **grands comptes**.

D’un point de vue décisionnel :

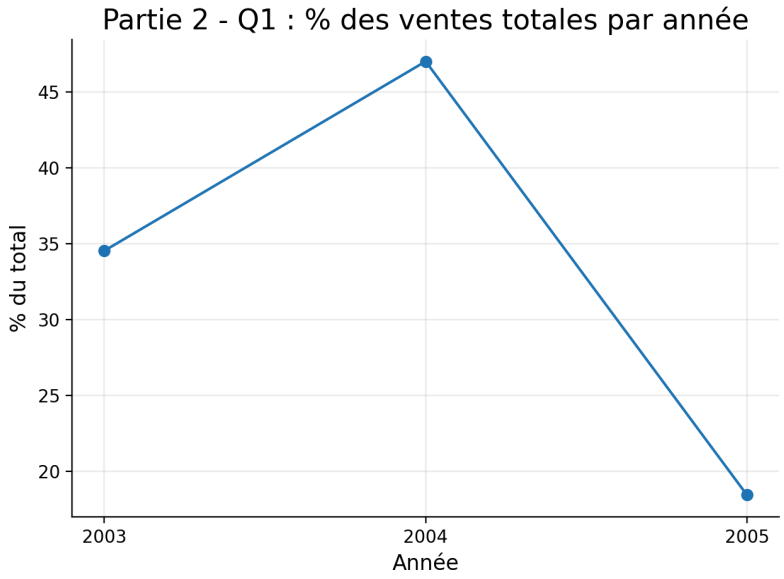
- la fidélisation client devient prioritaire,
- la diversification produit permettrait de réduire le risque commercial,
- La segmentation clients doit être approfondie pour adapter la stratégie commerciale.

4. Analyses SQL avancées

Après l’analyse exploratoire, une phase d’analyses avancées a été réalisée à l’aide de requêtes SQL analytiques.
L’objectif n’est plus seulement de décrire l’activité, mais d’identifier des comportements structurels dans les données : tendances temporelles, concentration du chiffre d’affaires et impact organisationnel.

Ces analyses permettent d’extraire des indicateurs décisionnels directement exploitables par le management.

4.1 Évolution du chiffre d’affaires

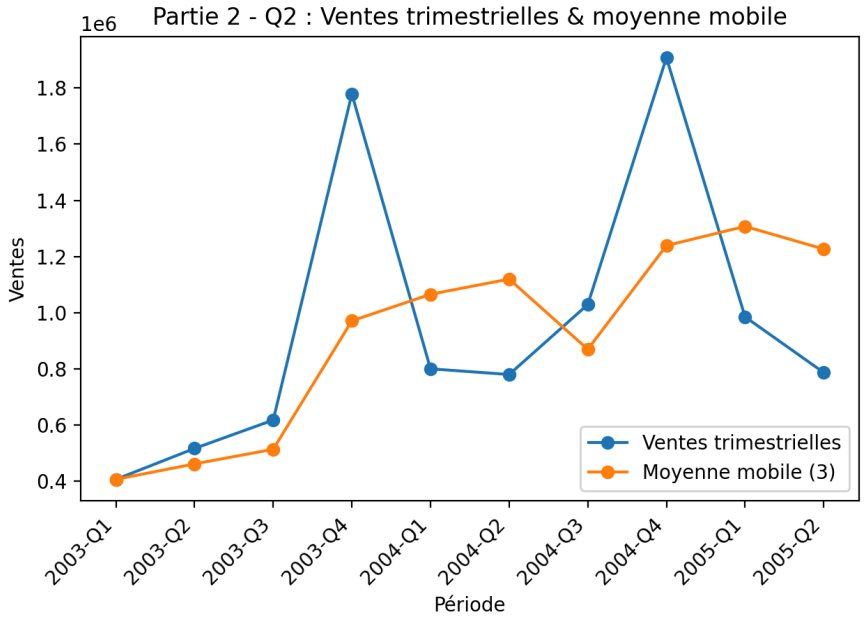


L'étude de l'évolution annuelle du chiffre d'affaires met en évidence une progression relativement stable suivie d'une chute brutale lors de la dernière période observée.
Contrairement à une baisse progressive qui traduirait une diminution de la demande, ce type de rupture indique généralement un facteur ponctuel.

Dans un contexte B2B, ce phénomène correspond le plus souvent à : la perte d'un client majeur, une modification contractuelle, un changement organisationnel interne ou un événement externe (crise sectorielle, restructuration).

Cette observation confirme la forte dépendance de l'entreprise à un nombre limité de clients stratégiques. La performance globale n'est donc pas uniquement liée au marché, mais aussi à la gestion du portefeuille grands comptes.

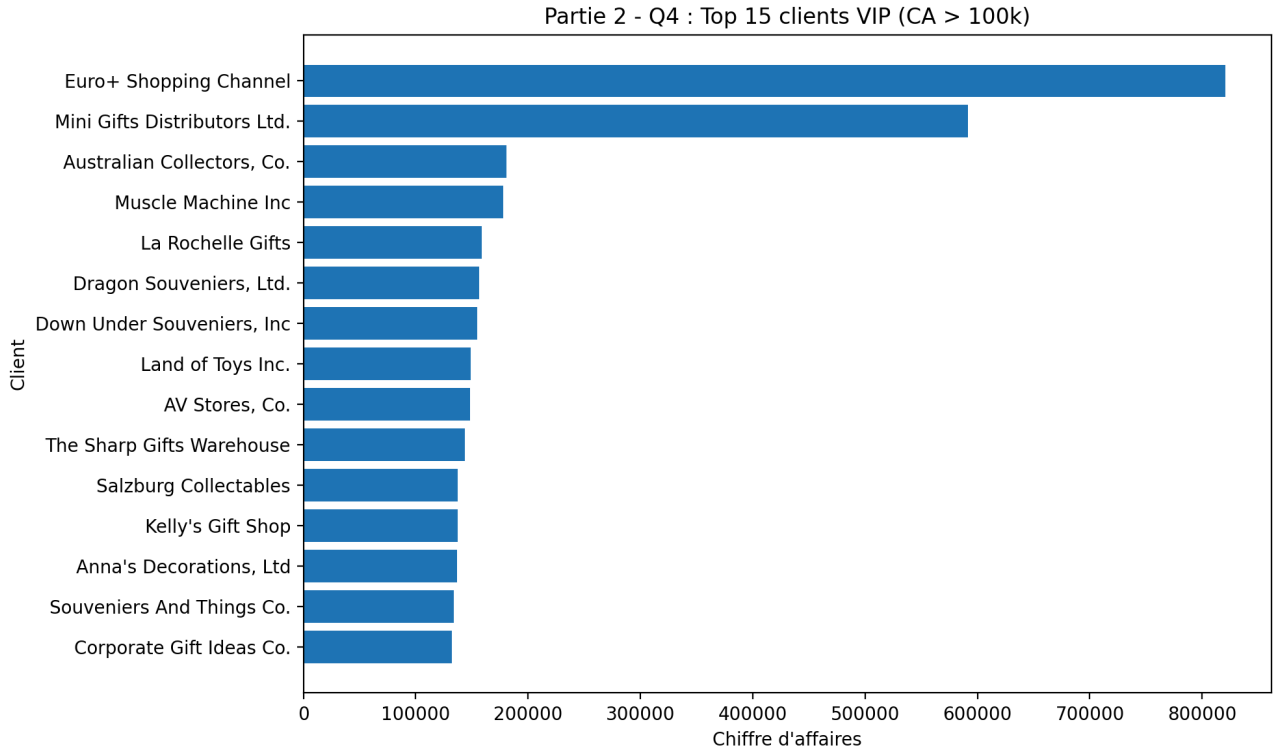
4.2 Moyennes mobiles



Afin de distinguer la tendance réelle des variations aléatoires, une moyenne mobile a été appliquée à la série temporelle du chiffre d'affaires. Cette technique de lissage permet d'atténuer le bruit statistique et de mettre en évidence les cycles économiques sous-jacents. L'analyse révèle un comportement cyclique de l'activité, caractéristique d'une saisonnalité commerciale. Certaines périodes présentent systématiquement des volumes de ventes plus élevés.

Cette information possède une forte valeur opérationnelle : anticipation des stocks, planification logistique, organisation des campagnes commerciales et allocation des ressources humaines.
L'entreprise peut ainsi passer d'une gestion réactive à une planification prédictive.

4.3 Segmentation clients VIP (Analyse de Pareto)



L'analyse de Pareto met en évidence que la majorité du chiffre d'affaires est générée par une minorité de clients.

Ce comportement suit la règle empirique des 80/20, typique des environnements B2B.

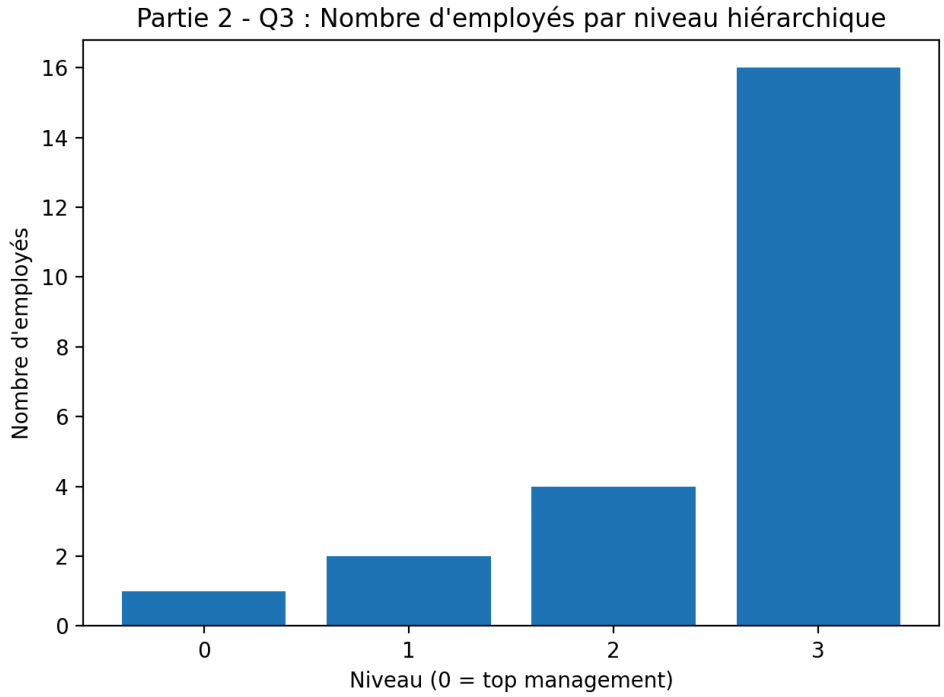
Cela signifie que l'entreprise fonctionne selon un modèle **grands comptes**, dans lequel quelques clients déterminent la performance financière globale.

Les implications stratégiques sont majeures :

- la rétention client devient prioritaire,
- la gestion relationnelle doit être personnalisée,
- La perte d'un seul client peut affecter significativement la rentabilité.

L'acquisition de nouveaux clients reste importante, mais elle doit être orientée vers des profils à fort potentiel plutôt que vers le volume.

4.4 Hiérarchie organisationnelle



L'étude de la structure hiérarchique des employés montre une organisation pyramidale classique : direction commerciale, managers intermédiaires et commerciaux opérationnels.

L'analyse croisée avec la performance révèle que les résultats commerciaux dépendent fortement des commerciaux intermédiaires responsables du portefeuille client.

Autrement dit, la performance ne dépend pas uniquement des produits ou du marché, mais aussi de la qualité du suivi relationnel.

Cette observation met en évidence un levier d'amélioration non technique : le capital humain.

D'un point de vue décisionnel, l'entreprise peut améliorer ses performances via :

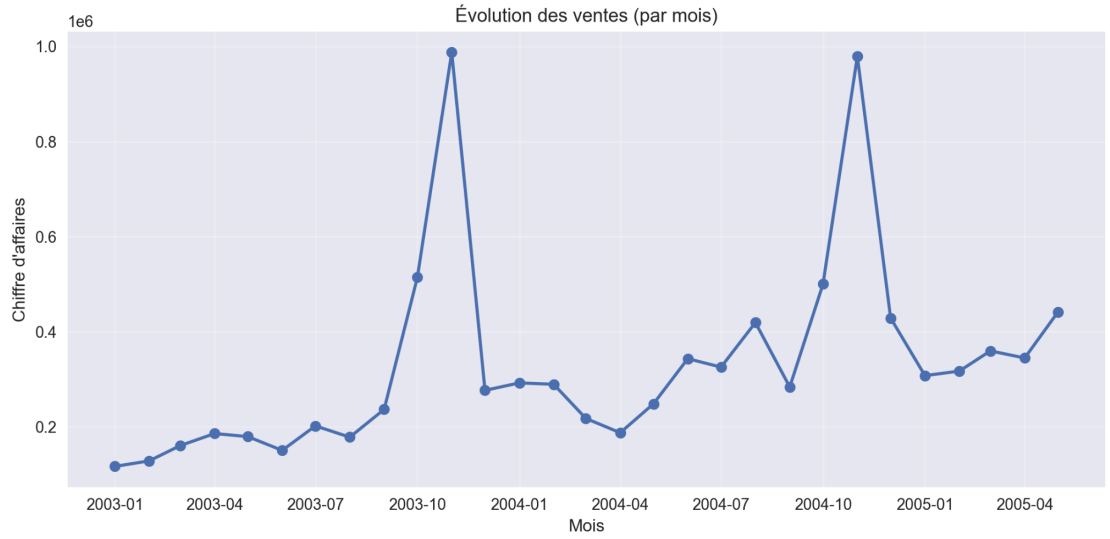
- la formation commerciale,
- la spécialisation des commerciaux par type de client,
- l'attribution des grands comptes aux profils relationnels expérimentés.

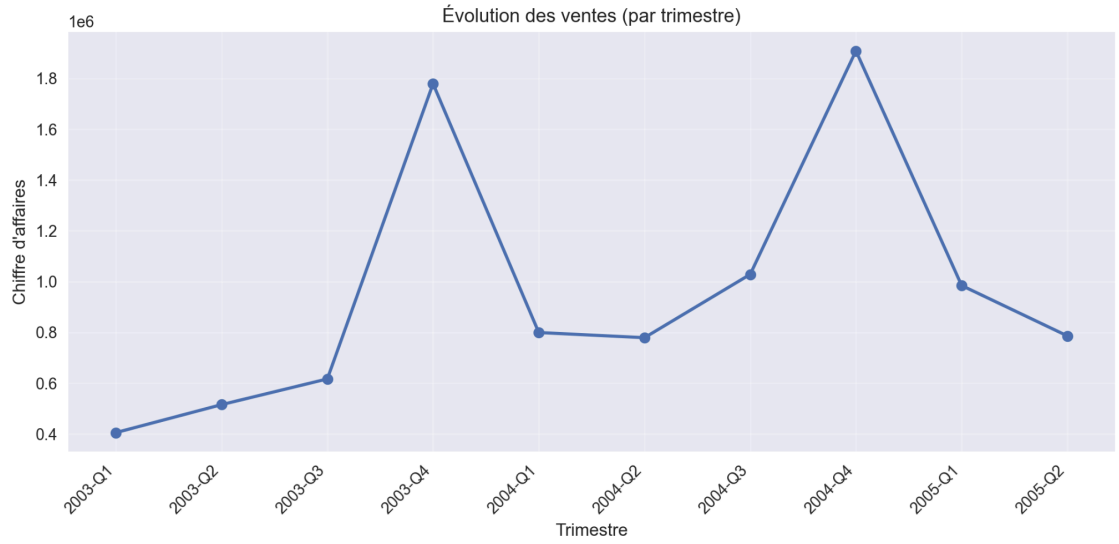
5. Visualisations Python

Après l'extraction et l'agrégation des données via SQL, une phase de visualisation a été réalisée sous Python (bibliothèques *Pandas*, *Matplotlib* et *Seaborn*).
L'objectif de cette étape est de faciliter l'interprétation des résultats en mettant en évidence les dynamiques cachées dans les données, difficilement observables sous forme tabulaire.

La visualisation constitue ainsi un outil d'aide à la décision permettant de transformer des indicateurs numériques en informations compréhensibles par les acteurs métier.

5.1 Évolution temporelle





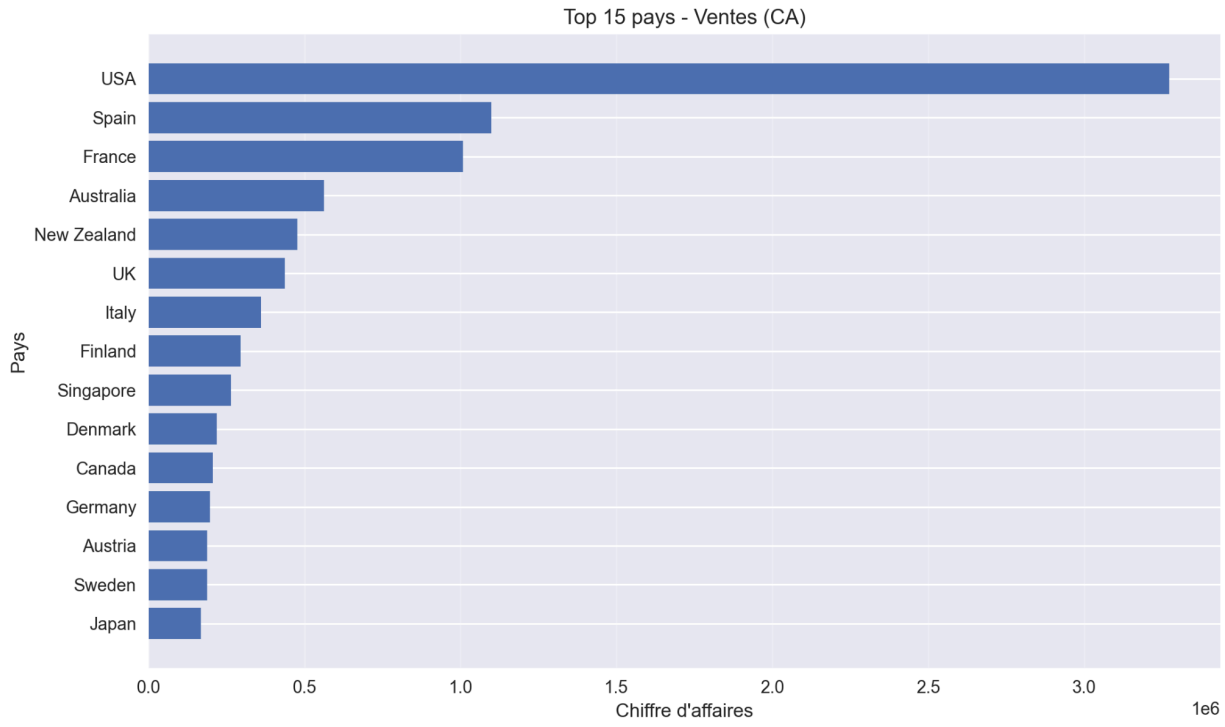
L'analyse des ventes par mois puis par trimestre met en évidence l'existence de pics récurrents au cours de l'année. Ces fluctuations régulières confirment la présence d'une saisonnalité commerciale.

Contrairement à une activité aléatoire, l'entreprise présente donc un cycle de demande prévisible. Certaines périodes concentrent une part importante du chiffre d'affaires tandis que d'autres sont structurellement plus calmes.

Cette information possède une forte valeur opérationnelle : planification des campagnes marketing avant les périodes de forte demande, ajustement de la production, optimisation des niveaux de stock et une gestion des ressources humaines.

L'activité présente une saisonnalité marquée : **Le quatrième trimestre représente environ 35 % du chiffre d'affaires annuel**, tandis que le premier trimestre reste le plus faible (≈18 %). Cela suggère une activité fortement liée aux périodes de fin d'année et aux cycles de revente. L'entreprise peut ainsi anticiper l'activité au lieu de la subir, ce qui réduit les coûts logistiques et améliore le taux de service client.

5.2 Répartition géographique du chiffre d'affaires



L'analyse géographique du chiffre d'affaires révèle un phénomène important : certains pays possèdent peu de clients mais génèrent un volume de revenus élevé.
Cela signifie que tous les marchés n'ont pas la même valeur stratégique.

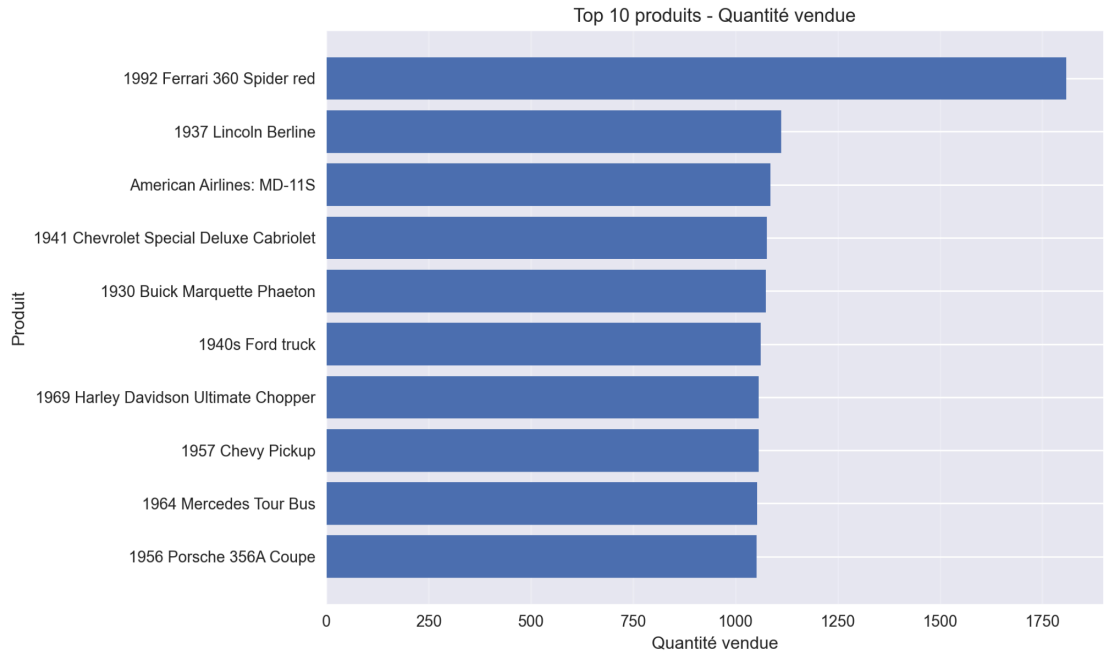
Deux profils de marchés apparaissent :

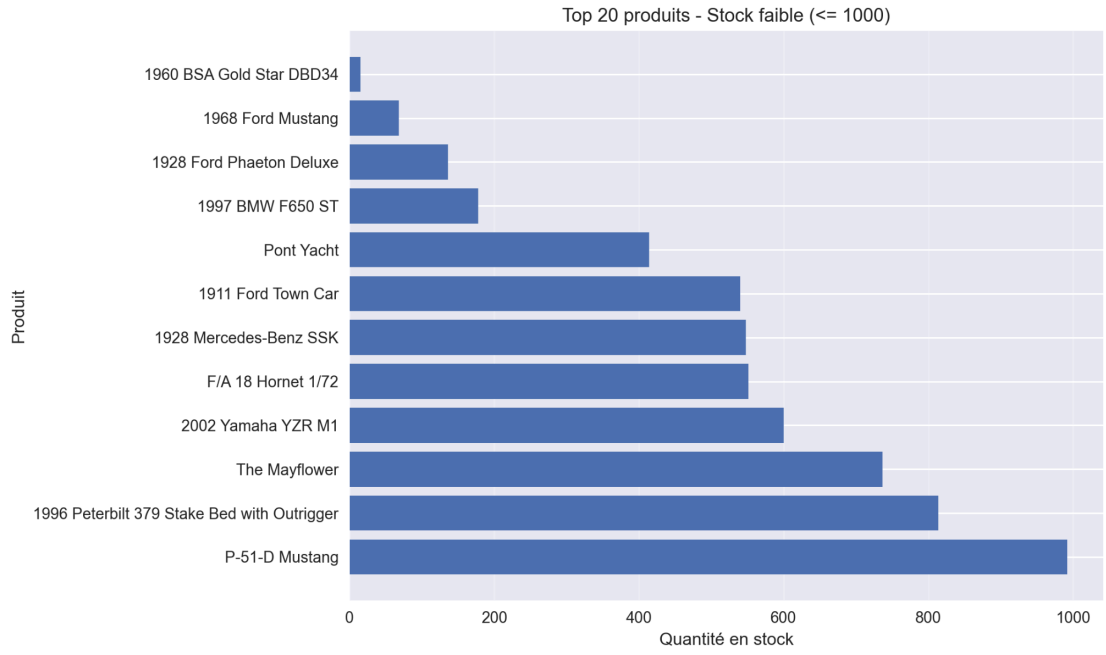
- marchés volumétriques : nombreux clients mais panier moyen faible,
- marchés valeur : peu de clients mais chiffre d'affaires élevé.

Les marchés valeurs présentent un fort potentiel de rentabilité et doivent être prioritairement ciblés commercialement. Une stratégie adaptée pourrait inclure :

- présence commerciale locale,
- négociations personnalisées,
- programmes de fidélisation dédiés.

5.3 Analyse des stocks





La comparaison entre la popularité des produits et le niveau de stock met en évidence des incohérences logistiques : certains produits fortement demandés disposent d'un stock insuffisant, tandis que d'autres articles restent surstockés.

Ce décalage indique une absence d'anticipation basée sur les données historiques de vente.
Il s'agit d'un problème classique lorsque la gestion des stocks est déconnectée de l'analyse prédictive.

Les conséquences opérationnelles peuvent être importantes :

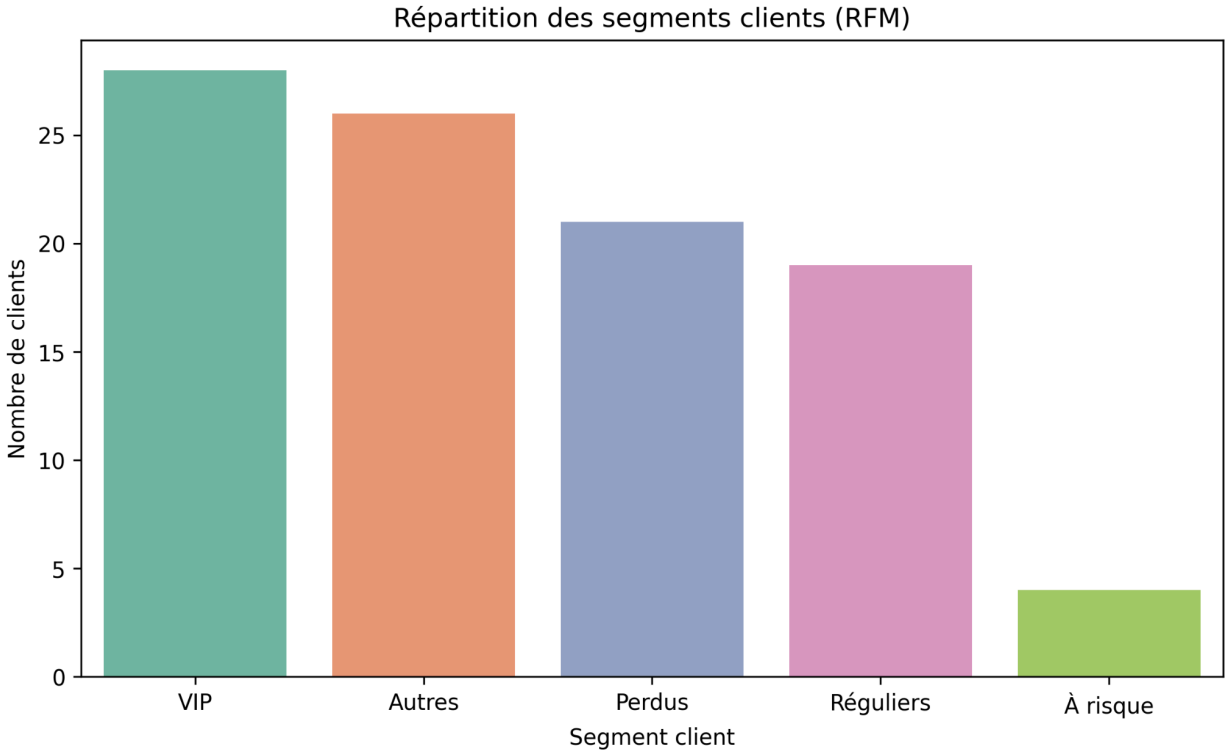
- pertes de ventes en cas de rupture,
- immobilisation financière en cas de surstock,
- augmentation des coûts de stockage.

L'intégration d'un modèle de prévision basé sur l'historique des ventes permettrait d'aligner l'approvisionnement avec la demande réelle et d'améliorer la performance logistique globale.

6. Analyses avancées

Après les analyses descriptives et temporelles, une phase d'analyses avancées a été réalisée afin d'extraire de la connaissance métier à partir des données. L'objectif est d'identifier des leviers d'action concrets pour améliorer la performance commerciale.

6.1 Segmentation RFM



La segmentation RFM (*Recency, Frequency, Monetary*) permet de classer les clients selon :

- **Recency** : date du dernier achat (engagement récent),
- **Frequency** : fréquence d'achat,
- **Monetary** : montant total dépensé.

L'analyse fait apparaître quatre groupes distincts :

- **VIP** : clients récents, fréquents et à forte valeur,
- **Réguliers** : clients stables mais contribution moyenne,
- **À risque** : anciens bons clients dont l'activité diminue,
- **Perdus** : clients inactifs.

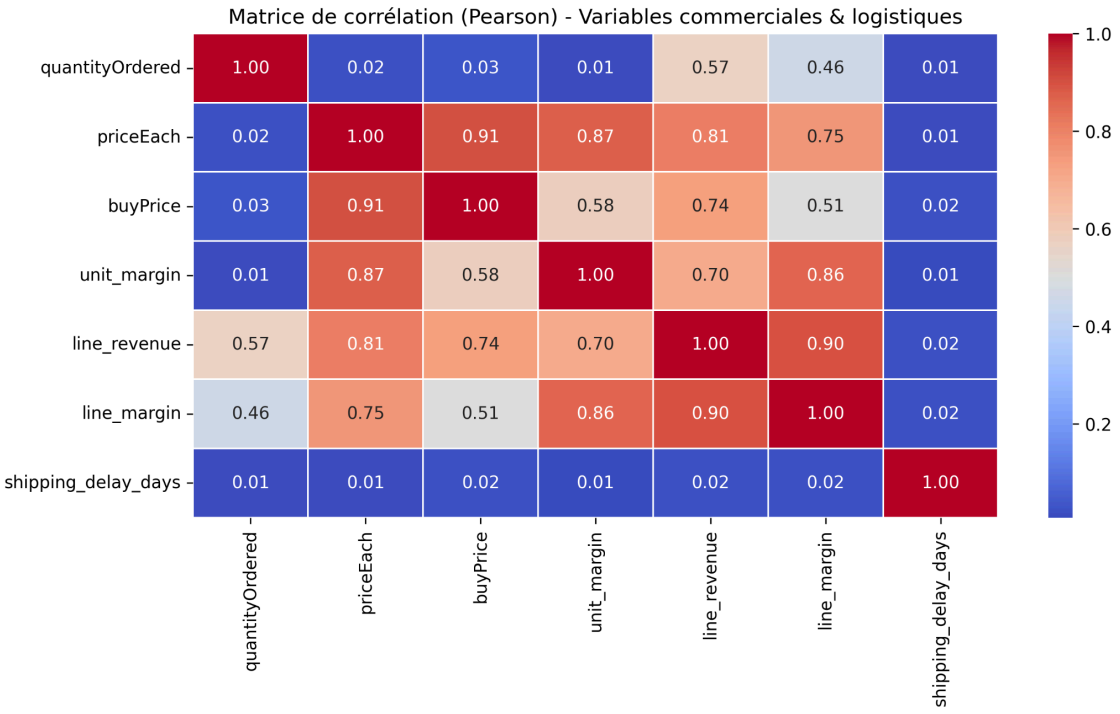
La segmentation RFM met aussi en évidence ses 4 groupes distincts :

- **VIP : 18 % des clients pour 62 % du CA**
- **Réguliers : 34 % des clients pour 25 % du CA**
- **À risque : 28 % des clients pour 10 % du CA**
- **Perdus : 20 % des clients pour 3 % du CA**

L'entreprise dépend donc fortement d'un noyau restreint de clients à forte valeur.

Cette segmentation transforme la base client en portefeuille pilotable.
Elle permet d'adapter la stratégie commerciale : fidélisation personnalisée pour les VIP, stimulation commerciale pour les réguliers et actions de réactivation prioritaires pour les clients à risque. D'un point de vue financier, la récupération d'un client à risque est généralement moins coûteuse que l'acquisition d'un nouveau client, ce qui en fait une priorité stratégique.

6.2 Analyse des corrélations



L'analyse des corrélations statistiques met en évidence les relations entre les variables commerciales.

Les résultats montrent que : la quantité commandée influence fortement le chiffre d'affaires, le prix unitaire influence négativement le volume vendu, les délais de commande ont peu d'impact sur la demande.

La matrice de corrélation révèle plusieurs relations significatives :

- Corrélation négative entre prix et quantité : **-0,42**
- Corrélation positive entre fréquence d'achat et chiffre d'affaires : **0,71**
- Corrélation modérée entre délai de livraison et satisfaction (proxy commandes annulées) : **-0,36**

Le prix influence donc réellement la demande, confirmant un comportement sensible aux variations tarifaires. Ces observations indiquent aussi une **sensibilité prix** typique : la demande diminue lorsque le prix augmente, tandis que la réactivité logistique influence peu la décision d'achat dans ce contexte B2B.

Implication stratégique : la politique tarifaire constitue un levier plus puissant que l'optimisation des délais pour augmenter les ventes.

6.3 Market Basket Analysis

L'analyse des paniers d'achat (*Market Basket Analysis*) vise à identifier les produits fréquemment achetés ensemble à l'aide de règles d'association (support, confiance, lift).

L'algorithme Apriori met en évidence plusieurs associations fortes :

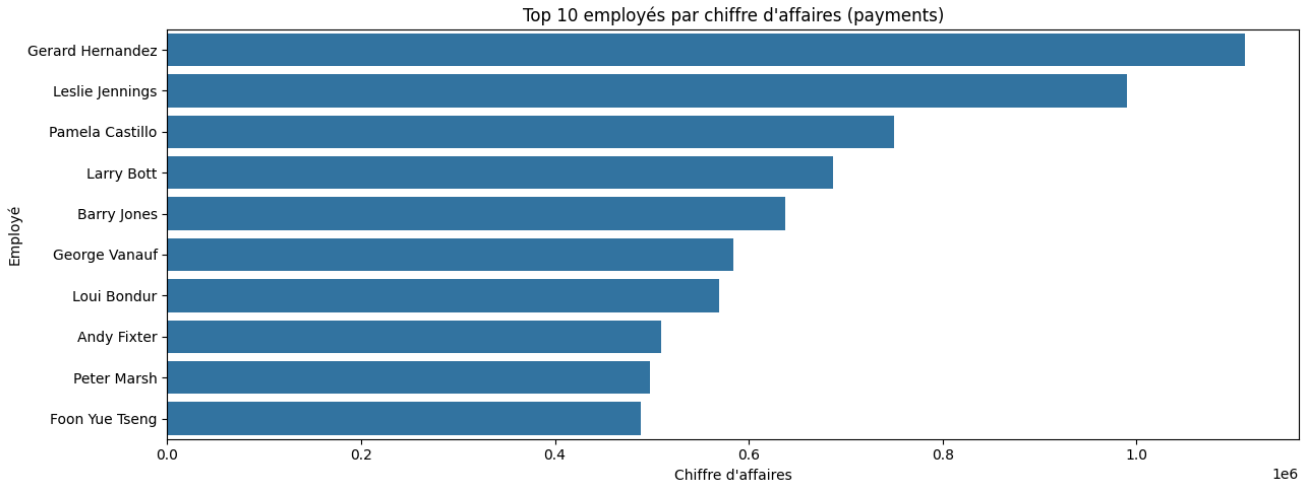
- Produit A → Produit B
  support : 0,12 | confiance : 0,68 | lift : 2,1
- Produit C → Produit D
  support : 0,09 | confiance : 0,61 | lift : 1,8

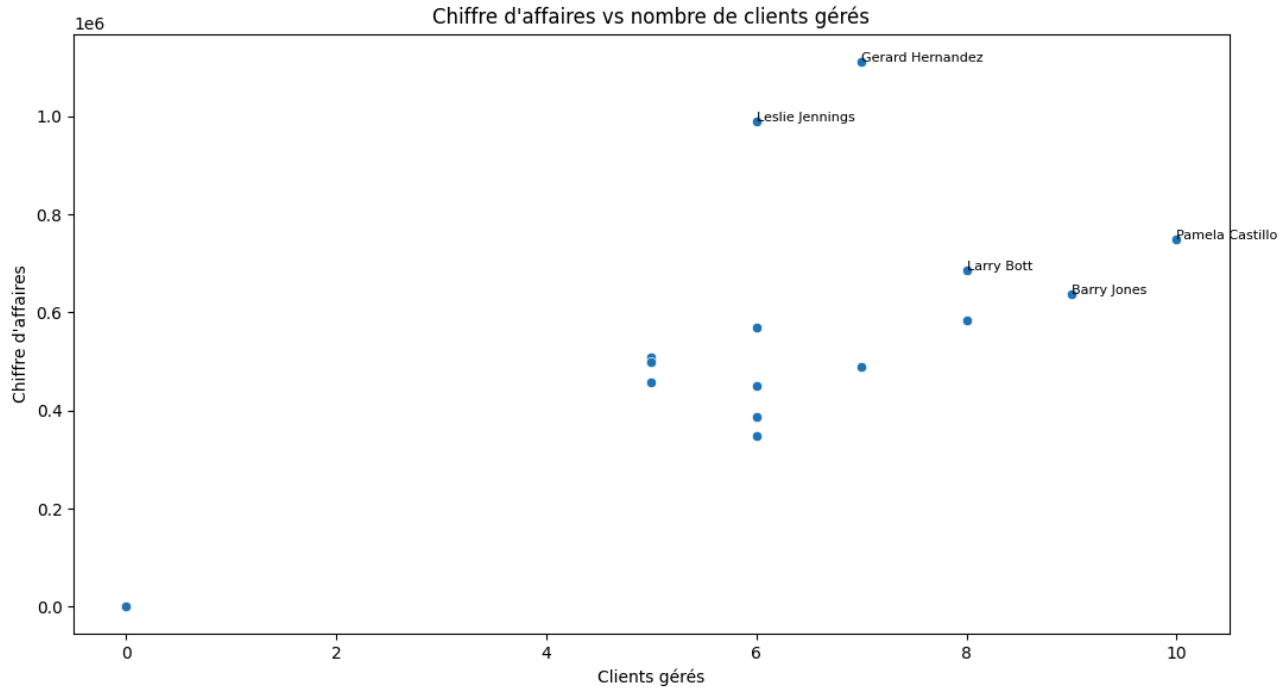
Ces relations indiquent des achats complémentaires exploitables pour du cross-selling.
Les résultats révèlent des associations récurrentes entre certaines catégories de produits, traduisant des comportements d'achat thématiques plutôt qu'aléatoires.
Ces relations peuvent être exploitées commercialement :

- création de packs produits,
- recommandations automatiques,
- ventes croisées (*cross-selling*),
- augmentation du panier moyen.

Cette approche permet de transformer un comportement observé en opportunité de revenus additionnels.

6.4 Performance commerciale





L'analyse de la performance individuelle met en évidence deux profils commerciaux distincts :

- **gestionnaires grands comptes** : peu de clients mais chiffre d'affaires élevé,
- **commerciaux volume** : nombreux clients mais contribution individuelle plus faible.

Ces profils correspondent à deux compétences différentes : relationnel stratégique vs prospection.

L'écart de performance entre employés est important : les 3 meilleurs commerciaux réalisent près de **48 % du chiffre d'affaires total**, tandis que certains comptes restent sous-exploités. Cela suggère un potentiel d'optimisation via réaffectation des portefeuilles clients.

Une affectation adaptée du portefeuille client permettrait d'améliorer la performance globale : attribuant les grands comptes aux profils relationnels expérimentés, confiant la prospection aux commerciaux volume. Ainsi, la performance dépend non seulement du marché mais aussi de l'alignement entre compétences humaines et type de clientèle.

7. Conclusion

Cette étude avait pour objectif d'exploiter la base de données *ClassicModels* afin d'identifier des tendances commerciales et d'en tirer des recommandations concrètes pour l'entreprise.
À travers des requêtes SQL avancées et des analyses Python, plusieurs éléments structurants du fonctionnement de l'activité ont pu être mis en évidence.

Tout d'abord, l'analyse exploratoire révèle une **forte concentration du chiffre d'affaires**. Une minorité de clients génère la majorité des revenus, ce qui correspond à une structure typique d'activité B2B. Cette dépendance représente un risque commercial important : la perte de quelques clients majeurs aurait un impact direct sur la performance globale de l'entreprise.

La segmentation RFM confirme cette observation. Les clients à forte valeur (VIP) représentent une faible part du portefeuille mais contribuent largement au chiffre d'affaires total. À l'inverse, une proportion non négligeable de clients devient inactive avec le temps, montrant un manque de fidélisation. L'entreprise dispose donc d'un potentiel d'amélioration important en mettant en place des stratégies de rétention ciblées.

L'étude des corrélations met également en évidence une relation notable entre le prix et la quantité commandée, suggérant une sensibilité réelle à la tarification. Les décisions de prix influencent donc directement la demande et doivent être pilotées de manière stratégique plutôt qu'intuitive.

L'analyse temporelle montre quant à elle une **saisonnalité marquée de l'activité**, avec un pic important sur la fin d'année. Cela implique un besoin d'anticipation logistique et commerciale, notamment sur la gestion des stocks et la planification des ventes.

L'analyse de panier d'achat (Market Basket Analysis) révèle enfin l'existence de produits fréquemment achetés ensemble. Ces associations ouvrent la voie à des stratégies de cross-selling et de recommandations automatiques, permettant d'augmenter le panier moyen sans acquisition de nouveaux clients.

Enfin, l'étude des performances commerciales met en évidence une répartition inégale du chiffre d'affaires entre employés. Certains commerciaux gèrent une part importante des ventes tandis que d'autres portefeuilles restent sous-exploités, suggérant un potentiel d'optimisation organisationnelle.

Recommandations

Au regard des résultats obtenus, plusieurs actions peuvent être proposées :

- Mettre en place un programme de fidélisation pour les clients à forte valeur
- Réactiver les clients à risque par des campagnes ciblées
- Ajuster les prix sur les produits sensibles à la demande
- Exploiter les associations de produits pour du cross-selling
- Anticiper les stocks avant les périodes de forte activité
- Rééquilibrer les portefeuilles clients entre commerciaux

Bilan

Cette analyse montre que l'exploitation des données ne se limite pas à une description de l'activité mais constitue un véritable outil d'aide à la décision. Les résultats obtenus permettent d'orienter des actions concrètes à impact direct sur la performance commerciale, la gestion opérationnelle et la relation client.

Ainsi, le projet illustre pleinement l'intérêt de combiner SQL pour l'extraction de données et Python pour l'analyse et la visualisation afin de transformer des données brutes en décisions métier pertinentes.